

Aprendizado Não Supervisionado: O Algoritmo K-means

João Victor Moreira Cardoso

12 de junho de 2026

Sumário

RECAPITULAÇÃO: APRENDIZADO NÃO-SUPERVISIONADO

O ALGORITMO K-MEANS

PRÓXIMOS PASSOS


REFERÊNCIAS

RECAPITULAÇÃO: APRENDIZADO NÃO-SUPERVISIONADO

As Três Tarefas Fundamentais

O Aprendizado Não-Supervisionado visa descobrir estruturas intrínsecas nos dados sem rótulos.


As Três Tarefas Fundamentais




Clustering: Agrupamento de dados similares

As Três Tarefas Fundamentais

Density Estimation: Understanding Data Distribution



*Density estimation reveals where data points are concentrated
KDE provides a smooth, continuous estimate of the probability density*




Estimativa de Densidade: Distribuição dos dados


As Três Tarefas Fundamentais

Dimensionality Reduction: Simplifying Complex Data (PCA - Principal Component Analysis)

Original Data: 3 Dimensions
(3D Swiss Roll)



After PCA: Reduced to 2 Dimensions
Preserves 40.9% + 30.7% = 71.6% of variance




Dimensionality reduction transforms data from 3D to 2D while preserving the most important structure and relationships

Redução de Dimensionalidade: Projeção em espaços menores

- **Cluster:** Conjunto de pontos com alta similaridade interna.
- **Centróide:** O protótipo ou centro de gravidade de um cluster.
- **Kernel:** Função que mapeia dados para espaços de maior dimensão.

Mapa Conceitual do Domínio



A seguir, detalharemos o algoritmo fundamental de Clustering: o **K-means**.

O ALGORITMO K-MEANS

Formalismo Conceitual

- **Objetivo:** Particionar N observações em K grupos distintos baseados na proximidade.
- **Premissa:** Cada ponto pertence ao cluster com a média (centróide) mais próxima.
- **Atribuição Rígida (Hard):** Cada dado é atribuído exclusivamente a um único cluster por vez.
- **Medida de Erro:** O algoritmo busca minimizar a soma dos quadrados das distâncias intra-cluster (Inércia).

Links úteis

- Material Auxiliar (Resumo Técnico):
https://github.com/Zuluke/kmeans/blob/main/_Resumo__AM.pdf
- Códigos e Figuras Demonstrativas:
<https://github.com/Zuluke/kmeans/blob/main/>

Considerando $K = 2$ em um conjunto de dados plano:

1. **Inicialização:** Dois centros são posicionados aleatoriamente no espaço.
2. **Atribuição:** Pontos são coloridos conforme o centro mais próximo (divisão por mediatriz).
3. **Atualização:** Os centros “saltam” para o meio geométrico de suas respectivas cores.
4. **Convergência:** Repete-se até que os centros estabilizem e nenhum ponto troque de grupo.

Visualização do K-means




Figura 1: Visualização do funcionamento do K-means.

Desejamos minimizar a função de custo J :

Função de Custo (Inércia ou Função de Distorção)

É a Soma dos Quadrados das Distâncias (WCSS ou SSE)

$$J = \sum_{n=1}^N \sum_{k=1}^K r_{nk} \|x_n - \mu_k\|^2$$

Onde:

- $r_{nk} \in \{0, 1\}$ é a variável indicadora de atribuição do ponto x_n ao cluster k .
- μ_k é o vetor protótipo representando o centro do cluster k .

Atualização dos Centróides: Derivação

Para atualizar o valor do centróide, derivamos a função J em relação a μ_k e igualamos a zero:

Derivada da Função de Custo

$$\frac{\partial J}{\partial \mu_k} = 2 \sum_{n=1}^N r_{nk} (x_n - \mu_k) = 0$$

Isolando μ_k , obtemos a equação de atualização:

Equação do Centróide

$$\mu_k = \frac{\sum_n r_{nk} x_n}{\sum_n r_{nk}}$$

Convergência garantida: a cada iteração, J é reduzido, garantindo convergência (mesmo que a um mínimo local) [MacQueen].

Ciclo Iterativo: Passos E e M

O K-means opera através da otimização alternada de J :

Passo 1 (Atribuição): Minimiza J em relação a r_{nk} (mantendo μ_k fixo). Cada ponto escolhe o centro mais próximo:

$$r_{nk} = \begin{cases} 1 & \text{se } k = \arg \min_j \|x_n - \mu_j\|^2 \\ 0 & \text{caso contrário} \end{cases}$$

Passo 2 (Atualização): Minimiza J em relação a μ_k (mantendo r_{nk} fixo). O novo centro é a média dos pontos atribuídos:

$$\mu_k = \frac{\sum_n r_{nk} x_n}{\sum_n r_{nk}}$$

Exemplo Didático Passo-a-Passo

Novamente, o pseudoalgoritmo considerando $K = 2$ em um conjunto de dados plano é:

1. **Inicialização:** Dois centros são posicionados aleatoriamente no espaço.
2. **Atribuição:** Pontos são coloridos conforme o centro mais próximo (divisão por mediatriz).
3. **Atualização:** Os centros “saltam” para o meio geométrico de suas respectivas cores.
4. **Convergência:** Repete-se até que os centros estabilizem e nenhum ponto troque de grupo.

Exemplo Didático Passo-a-Passo

Usando a sequência de passos anterior, como resolver o seguinte problema? Vamos usar o K-means em um exemplo simples para entender o mecanismo.

Dados (6 pontos em 2D):

Ponto	A	B	C	D	E	F
x ($\mathbf{x}_1$)	1	2	3	8	9	10
y ($\mathbf{x}_2$)	2	2	2	8	8	8

Visualmente, há dois grupos: $\{A, B, C\}$ no canto inferior esquerdo e $\{D, E, F\}$ no canto superior direito.

Exemplo Didático Passo-a-Passo

Passo 1: Escolher $K = 2$ e inicializar centróides aleatórios. Suponha:

- Centróide 1: $C_1 = (1.5, 2.5)$ (próximo a A e B)
- Centróide 2: $C_2 = (8.5, 7.5)$ (próximo a E e F)

Passo 2 (Atribuição): Calcular a distância de cada ponto a cada centróide (distância Euclidiana: $\sqrt{(x_p - x_c)^2 + (y_p - y_c)^2}$).

Para ponto $A = (1, 2)$:

- Distância a C_1 : $\sqrt{(1 - 1.5)^2 + (2 - 2.5)^2} = \sqrt{0.25 + 0.25} = \sqrt{0.5} \approx 0.71$
- Distância a C_2 : $\sqrt{(1 - 8.5)^2 + (2 - 7.5)^2} = \sqrt{56.25 + 30.25} = \sqrt{86.5} \approx 9.30$
- A é atribuído ao cluster 1.

Exemplo Didático Passo-a-Passo

Para ponto $D = (8, 8)$:

- Distância a C_1 : $\sqrt{(8 - 1.5)^2 + (8 - 2.5)^2} = \sqrt{42.25 + 30.25} = \sqrt{72.5} \approx 8.51$
- Distância a C_2 : $\sqrt{(8 - 8.5)^2 + (8 - 7.5)^2} = \sqrt{0.25 + 0.25} = \sqrt{0.5} \approx 0.71$
- D é atribuído ao cluster 2.

O processo continua para todos os pontos. Provavelmente, $\{A, B, C\}$ vão para o cluster 1, e $\{D, E, F\}$ vão para o cluster 2.

Passo 3 (Atualização): Recalcular centróides como a média dos pontos em cada cluster.

- Cluster 1: média de $\{(1, 2), (2, 2), (3, 2)\} = ((1 + 2 + 3)/3, (2 + 2 + 2)/3) = (6/3, 6/3) = (2, 2)$
- Cluster 2: média de $\{(8, 8), (9, 8), (10, 8)\} = ((8 + 9 + 10)/3, (8 + 8 + 8)/3) = (27/3, 24/3) = (9, 8)$

Exemplo Didático Passo-a-Passo

Passo 4: Repetir atribuição com os novos centróides $(2, 2)$ e $(9, 8)$. Os pontos não mudam de cluster (convergência). Fim.

O K-means encontrou corretamente os dois grupos!

PRÓXIMOS PASSOS

Preâmbulo para o Próximo Assunto

Apesar de sua eficiência, o K-means possui limitações: assume clusters esféricos e é sensível a outliers.

Próxima Fronteira

Para definir o número K de clusters, estudaremos o **Método do Cotovelo (Elbow Method)**: heurística que plota a inércia em função de K e busca o ponto de “curvatura” onde o ganho marginal diminui.

Além disso, exploraremos o **Algoritmo EM (Expectation-Maximization)** e os **Modelos de Mistura Gaussiana (GMM)**, que permitem uma abordagem probabilística “suave”(soft assignment) ao agrupamento.

REFERÊNCIAS

Referências

- **BISHOP, Christopher M.** *Pattern Recognition and Machine Learning*. Springer, 2006.
- **DUDA, Richard O.; HART, Peter E.; STORK, David G.** *Pattern Classification*. Wiley, 2001.
- **MITCHELL, Tom M.** *Machine Learning*. McGraw Hill, 1997.
- **MACQUEEN, James**, *Some methods for classification and analysis of multivariate observations*, 1967.

OBRIGADO!!